

GABRIEL YOGI

LLM Systems Engineer | Inference, Performance & GenAI

github.com/MadrasLe | huggingface.co/Madras1 | linkedin.com/in/gabriel-yogi | gabriel.yukio2205@email.com

RESUMO PROFISSIONAL

Engenheiro de Machine Learning e pesquisador independente com foco em **LLM Systems, model architecture e inferência de alto desempenho**. Criador do **MegaGemm**, ecossistema full-stack de inferência com runtime GPU, **160+ custom GPU kernel entry points**, artefatos compilados, estado persistente, inferência distribuída e runtime CPU nativo standalone. Experiência cobrindo dados para pré-treinamento, treinamento Transformer/MoE, CUDA/Triton/C++, sistemas distribuídos, RAG e avaliação reproduzível.

HABILIDADES TÉCNICAS

LLM Systems & Inferência: CUDA C++, Triton, PyTorch, C/C++, AVX2/NEON, custom GPU kernels, paged/layer-aware KV cache, continuous batching, quantização INT8/INT4/AWQ, profiling e benchmarking

Treinamento de LLMs: Transformers, DeepSpeed, JAX/Flax, Mixture-of-Experts, Top-K routing, Flash Attention 2, Liger Kernels, BF16, SFT, LoRA/DoRA, model merging

Agentes & Sistemas Distribuídos: Python, AsyncIO, SQLite, workflows em grafo, sharding, leases, retries, auditoria, MCP/A2A, tool calling

RAG & Data Systems: FastAPI, FAISS, BM25, RRF, Sentence-Transformers, CrossEncoder, Parquet, data curation, LLM-as-a-Judge, pandas, NumPy

Infraestrutura & Ferramentas: Docker, CMake, Prometheus, REST APIs, Git/GitHub, Hugging Face Hub, Kaggle, Google Colab, Databricks

Idiomas: Português nativo; Inglês com leitura/escrita avançadas e fala intermediária

PROJETOS SELECIONADOS & EXPERIÊNCIA TÉCNICA

MegaGemm | *Full-Stack LLM Inference & Systems Runtime – Autor/Arquiteto Principal* | Pesquisa Independente | [GitHub](#)
– Projetei e desenvolvi um **ecossistema full-stack de inferência para LLMs** em Python, PyTorch, Triton, CUDA e C/C++, cobrindo execução GPU, scheduler, paged/layer-aware KV cache, continuous batching, quantização, offload, serving e tooling de benchmark.

- Implementei **160+ custom GPU kernel entry points** (154 rotinas Triton JIT + 14 kernels CUDA no inventário atual), incluindo Paged Attention, MoE/grouped expert compute, linear/recurrent attention, scans, GEMV/GEMM quantizado, sparsity e operações fundidas.
- Criei caminhos especializados para arquiteturas não convencionais: **Qwen 3.5/GatedDeltaNet** com delta-rule recorrente/chunked e scans Hillis-Steele/Blelloch; e **Gemma 4** com atenção heterogênea, cross-layer KV sharing, PLE e routed MoE.
- Desenvolvi **MGX**, formato binário de artefatos runtime-ready que armazena pesos já materializados/transformados para reduzir trabalho de cold-start, e o **Prophet**, biblioteca persistente de KV/session state reutilizável entre processos e execuções.
- Desenvolvi **MegaMesh**, runtime distribuído para hardware heterogêneo com replica routing, layer sharding, transporte binário persistente **TTP**, continuous batching sobre shards e primitivas experimentais de sharding de **lm_head** e MLP.
- Desenvolvi **MicroGemm**, runtime CPU standalone em C/C++ **sem Python, PyTorch ou Hugging Face**, compilável com toolchain de sistema, com formato **.mgm**, conversor Safetensors nativo, tokenizer BPE, kernels INT8/INT4 AVX2/NEON e batching nativo.
- Benchmarks atuais: MegaGemm FP16 atingiu **93,1% do throughput geométrico do vLLM 0.27.1** em Qwen 2.5 3B/L4; MGX+Prophet atingiu **102,8%** do baseline de prefix cache medido; MicroGemm atingiu **1,286×** o throughput geométrico do llama.cpp no benchmark CPU pareado.

GTLM | *Pesquisador Independente em IA & Machine Learning Engineer* | [GitHub](#) | [Hugging Face](#) | 2025 – Presente
– Projetei e treinei do zero um modelo de linguagem causal **Sparse Mixture-of-Experts** **bilingue** com aproximadamente **2B parâmetros totais e 350M ativos por token**, usando roteamento Top-2 entre 16 especialistas por camada.

- Conduzi o treinamento sobre aproximadamente **15 bilhões de tokens em inglês e português brasileiro em uma única NVIDIA A100**, utilizando PyTorch, DeepSpeed, BF16, Flash Attention 2 e Liger Kernels.
- Implementei RoPE, RMSNorm, especialistas SwiGLU, embeddings compartilhados, balanceamento auxiliar do router e pipeline completo de datasets, checkpointing, retomada, avaliação e publicação compatível com Hugging Face.
- Obtive média de **56,2% em seis benchmarks zero-shot** com lm-evaluation-harness, superando as médias reportadas de Pythia-410M e GPT-2 Medium; código, documentação e checkpoints publicados sob licença Apache 2.0.

Mercor AI Detection Challenge | *Top 5 Global – Machine Learning* | Kaggle / Mercor AI
– Conquistei **Top 5 Global** em competição de detecção de conteúdo gerado por IA, superando centenas de competidores qualificados.

- Desenvolvi solução para poucos dados e textos curtos combinando múltiplos sinais, engenharia de features e ensemble de **DeBERTa + XGBoost**.
- A solução foi validada pela equipe de engenharia da Mercor e resultou em convite direto para oportunidade profissional após a competição.

- JadeAgent** | *Criador e Engenheiro Principal – Runtime Distribuído para Agentes de IA* | [GitHub](#) Open Source
- Projetei um runtime open-source para execução governada de agentes de IA, com workflows em grafo, comunicação mesh, tool calling e estado durável.
 - Implementei o **JGX**, camada de checkpoints, crash recovery, replay idempotente, event logs append-only, verificação de integridade e evidências de auditoria.
 - Desenvolvi arquitetura distribuída assíncrona com sharding por tenant/capability, leases, retries, dead-letter queue e seleção de workers por trust tier, capacidade e pressão de fila.
 - Implementei políticas executáveis para filesystem, rede, shell, delegação, tools e memória, além de benchmarks determinísticos contra Python puro e LangGraph em latência, recuperação e idempotência.

- JadeLLM** | *Criador e LLM Engineer* | [GitHub](#) | [Hugging Face](#) Open Source
- Criei uma família de modelos conversacionais em português brasileiro de **0,6B a 72B parâmetros**, baseada em arquiteturas Qwen2.5, Qwen3 e GPT-OSS.
 - Desenvolvi pipeline de SFT/destilação orientada por persona com Unsloth, LoRA, DoRA, full fine-tuning, merge de adapters e publicação automatizada; nove modelos oficiais e distribuições GGUF.
 - O ecossistema alcançou **33,8 mil downloads acumulados** no Hugging Face, incluindo **25,5 mil** via quantizações comunitárias e 2,2 mil no snapshot mais recente de 30 dias de agosto de 2026.

- Corpus PT-BR v1** | *Large-Scale LLM Data & ML Systems* | [Hugging Face](#) Open Source
- Construí uma infraestrutura de dados para LLMs que produziu um corpus PT-BR com **8,4M documentos e 6,29B tokens**, combinando 6,81M documentos reais curados com 1,59M documentos sintéticos (961M tokens).
 - Orquestrei geração sintética em escala entre **inferência local quantizada em GPU e múltiplos provedores de API**, com batch generation, diversidade de modelos/prompts e otimização de custo versus throughput.
 - Desenvolvi um pipeline de quality filtering **LLM-as-a-Judge** → **72K exemplos rotulados** → **fine-tuning de SBERT** → **scoring em GPU de milhões de documentos**, seguido por deduplicação MD5, normalização de schema e publicação em Parquet/Snappy.
 - Publiquei o corpus sob licença ODC-By no Hugging Face; o dataset recebeu **adoção independente da comunidade**, sendo utilizado como dado de treinamento pelo modelo público de terceiro .

- AetherMap** | *Engenheiro de IA Full-Stack – RAG Híbrido* | [GitHub](#) Open Source
- Desenvolvi plataforma para processar corpus TXT/CSV, organizar documentos em mapas semânticos 3D e responder perguntas com evidências e citações.
 - Implementei RAG híbrido com **FAISS + BM25 + RRF + CrossEncoder**, fine-tuning de MiniLM e suíte reproduzível de avaliação, ablação, LLM-as-judge e profiling de latência.
 - Em benchmark SQuAD-PT com 50 consultas por configuração, atingi **MRR 0,99, Hit@3 1,00, 97% de suporte correto das citações e 100% de precisão na recusa** de perguntas sem contexto.

PROJETOS ADICIONAIS & RECONHECIMENTOS

- Automated Stock Workflow** | [GitHub](#) GenAI / Visão
- Pipeline automatizado de geração e rotulagem de dados que produziu aproximadamente **150.000 imagens** e metadados, incluindo uso de Florence-2 para rotulagem visual.
- AlphaChecker** | *Reinforcement Learning* | [GitHub](#) Open Source
- Criei um agente inspirado em AlphaZero com aproximadamente **100 mil parâmetros** para jogo de damas, capaz de derrotar LLMs muito maiores em partidas avaliadas.

FORMAÇÃO ACADÊMICA

- Universidade Nove de Julho (UNINOVE)** São Paulo, Brasil
- Tecnólogo em Inteligência Artificial* 2025 – Presente (conclusão prevista: 2027)
- Formação complementada por pesquisa independente, desenvolvimento open-source e construção prática de sistemas de IA antes e durante a graduação.